



Classificação Automática de Frutas e Vegetais com YOLOv8 para Balanças Inteligentes em Supermercados

Disciplina: Visão Computacional | Professor: Rigel Fernandes | Instituição:
[IBMEC]

Autores: Daniel Lloyd, Thiago Borsoni, Bernardo Pinto



Motivação: O Desafio do Varejo Moderno

Contexto Atual

Balanças de autoatendimento em supermercados dependem de processos manuais lentos e propensos a erros

- Cliente busca produto em lista extensa
- Digitação incorreta de códigos
- Filas e tempo de espera elevado
- Perdas por classificação errada

Solução Inteligente

Visão computacional e deep learning transformam a experiência de compra

- Reconhecimento automático instantâneo
- Redução de erros humanos
- Agilidade no atendimento
- Melhor experiência do cliente



Descrição do Problema



Classificação Multi-Classe

Reconhecer diferentes tipos de frutas e vegetais automaticamente



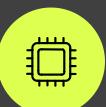
Sacolas Plásticas

Detectar itens com e sem embalagem transparente ou colorida



Latência Crítica

Resposta em tempo real para não atrasar o atendimento



Hardware Limitado

Executar em dispositivos de borda com recursos restritos

Base de Dados e Preparação

Dataset Original

Fruits & Vegetable Detection for YOLOv4

- Originalmente para detecção de objetos
- Adaptado para classificação
- Rótulos extraídos via regex dos nomes dos arquivos
- Atributo binário "Bag" criado

Taxonomias Criadas

8 classes sem considerar sacola

14 classes com variações:

- 6 frutas: with_bag e without_bag
- Raspberry e blackberries: apenas sem sacola

01

Extração de Rótulos

Regex aplicado aos nomes dos arquivos

02

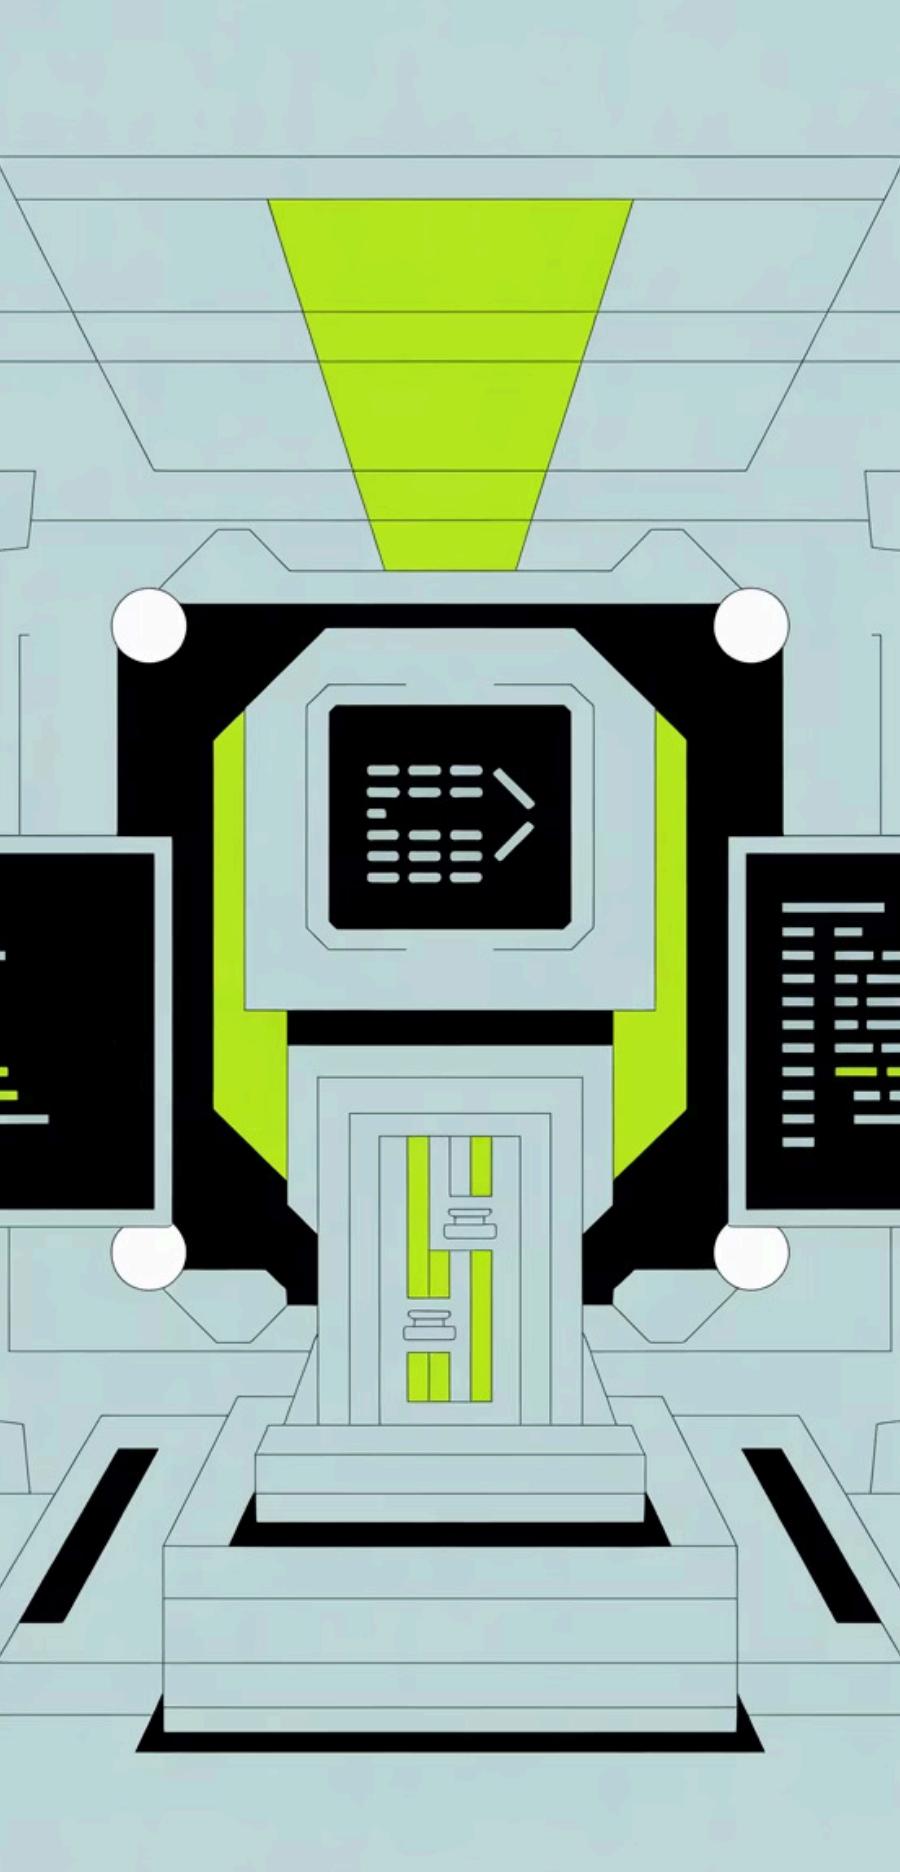
Criação de Estrutura

Pastas dataset/train e dataset/val organizadas

03

Divisão Estratificada

70% treino | 30% validação



Esforços de Desenvolvimento

Adaptação do Dataset

Conversão de formato de detecção para classificação com scripts personalizados

Automação de Pipeline

Criação automática de estrutura de pastas por classe para treino e validação

Fine-Tuning YOL0v8s

Modelo yolov8s-cls.pt | Imagens 224x224 | Batch size 16 | GPU/CUDA

Métricas Completas

Pipeline de avaliação com accuracy, precision, recall, F1 e matriz de confusão

- ☐ **Desafios:** Formato original complexo, classes desbalanceadas, ajuste fino de hiperparâmetros

Arquitetura e Metodologia

Pipeline YOL0v8s em Modo Classificação



Entrada

Imagen da balança

Pré-processamento

Resize 224×224 | Normalização

YOL0v8s

Backbone + Classificador

Saída

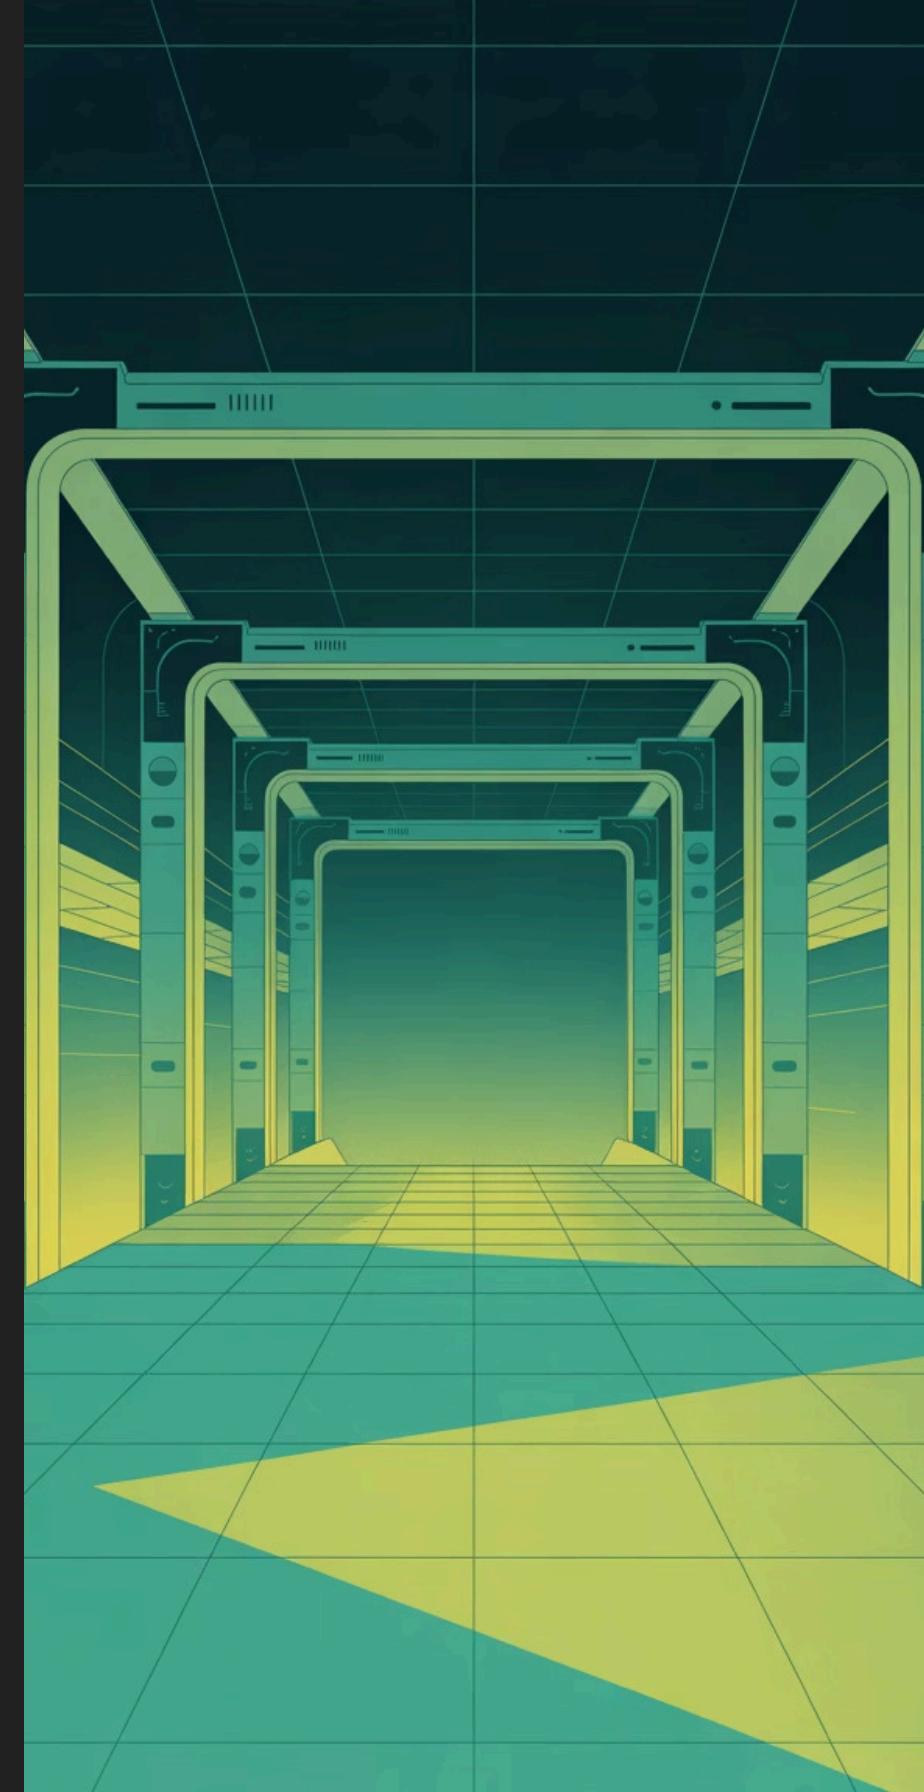
Classe predita

YOL0v8 Classificação

- Balanceamento entre precisão e velocidade
- Otimizado para edge devices

Aceleração GPU

- CUDA para treinamento rápido
- Processamento em lote eficiente



Resultados Quantitativos

100%

Acurácia perfeita em ambas configurações

8 Classes sem considerar Sacola

100%

Accuracy

14 Classes (Com/Sem Sacola)

100%

Accuracy

- ❑ **Matriz de Confusão:** Perfeitamente diagonal em ambas configurações, sem erros de classificação

Resultados Qualitativos

Exemplos de Classificação Correta



Sacolas Transparentes

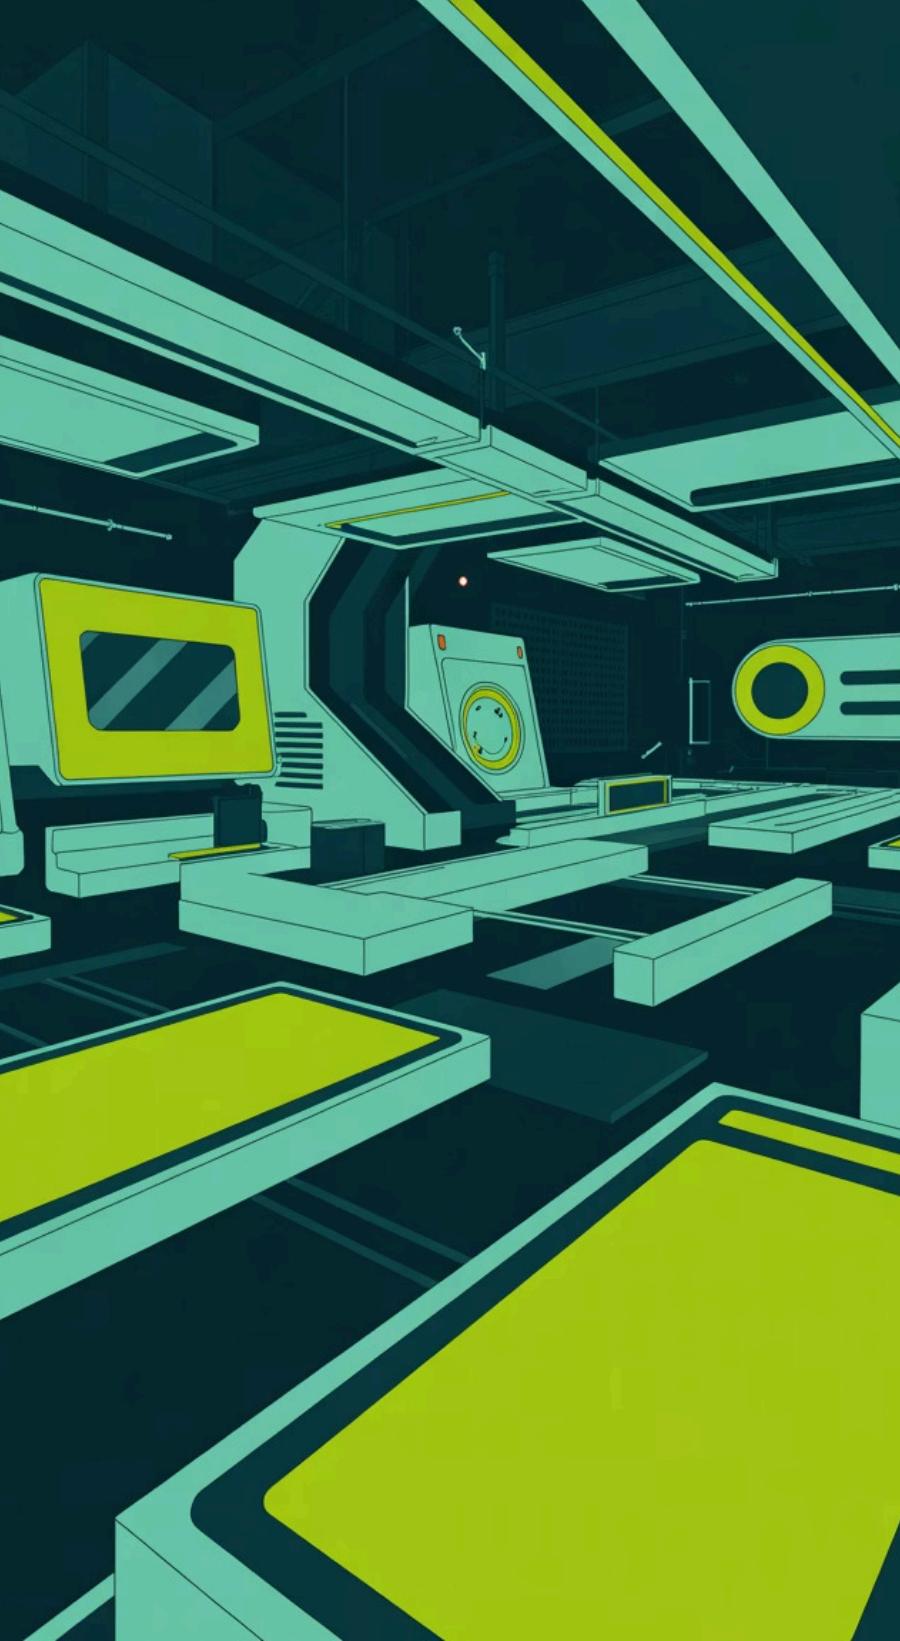
Reconhecimento preciso mesmo com plástico claro sobre o produto

Sacolas Coloridas

Classificação correta com embalagens azuis, pretas e escuras

Oclusões Parciais

Modelo mantém previsões mesmo com objetos sobrepostos



Testes de Robustez e Performance

Stress Test Visual

Versões da mesma imagem com variações extremas:

- **Bright:** Iluminação intensa aumentada
- **Dark:** Escurecimento significativo
- **Oclusão:** Bloco preto cobrindo parte da fruta

Resultado: Classe correta mantida em todos os cenários

Métricas Técnicas

Latência

~193 ms

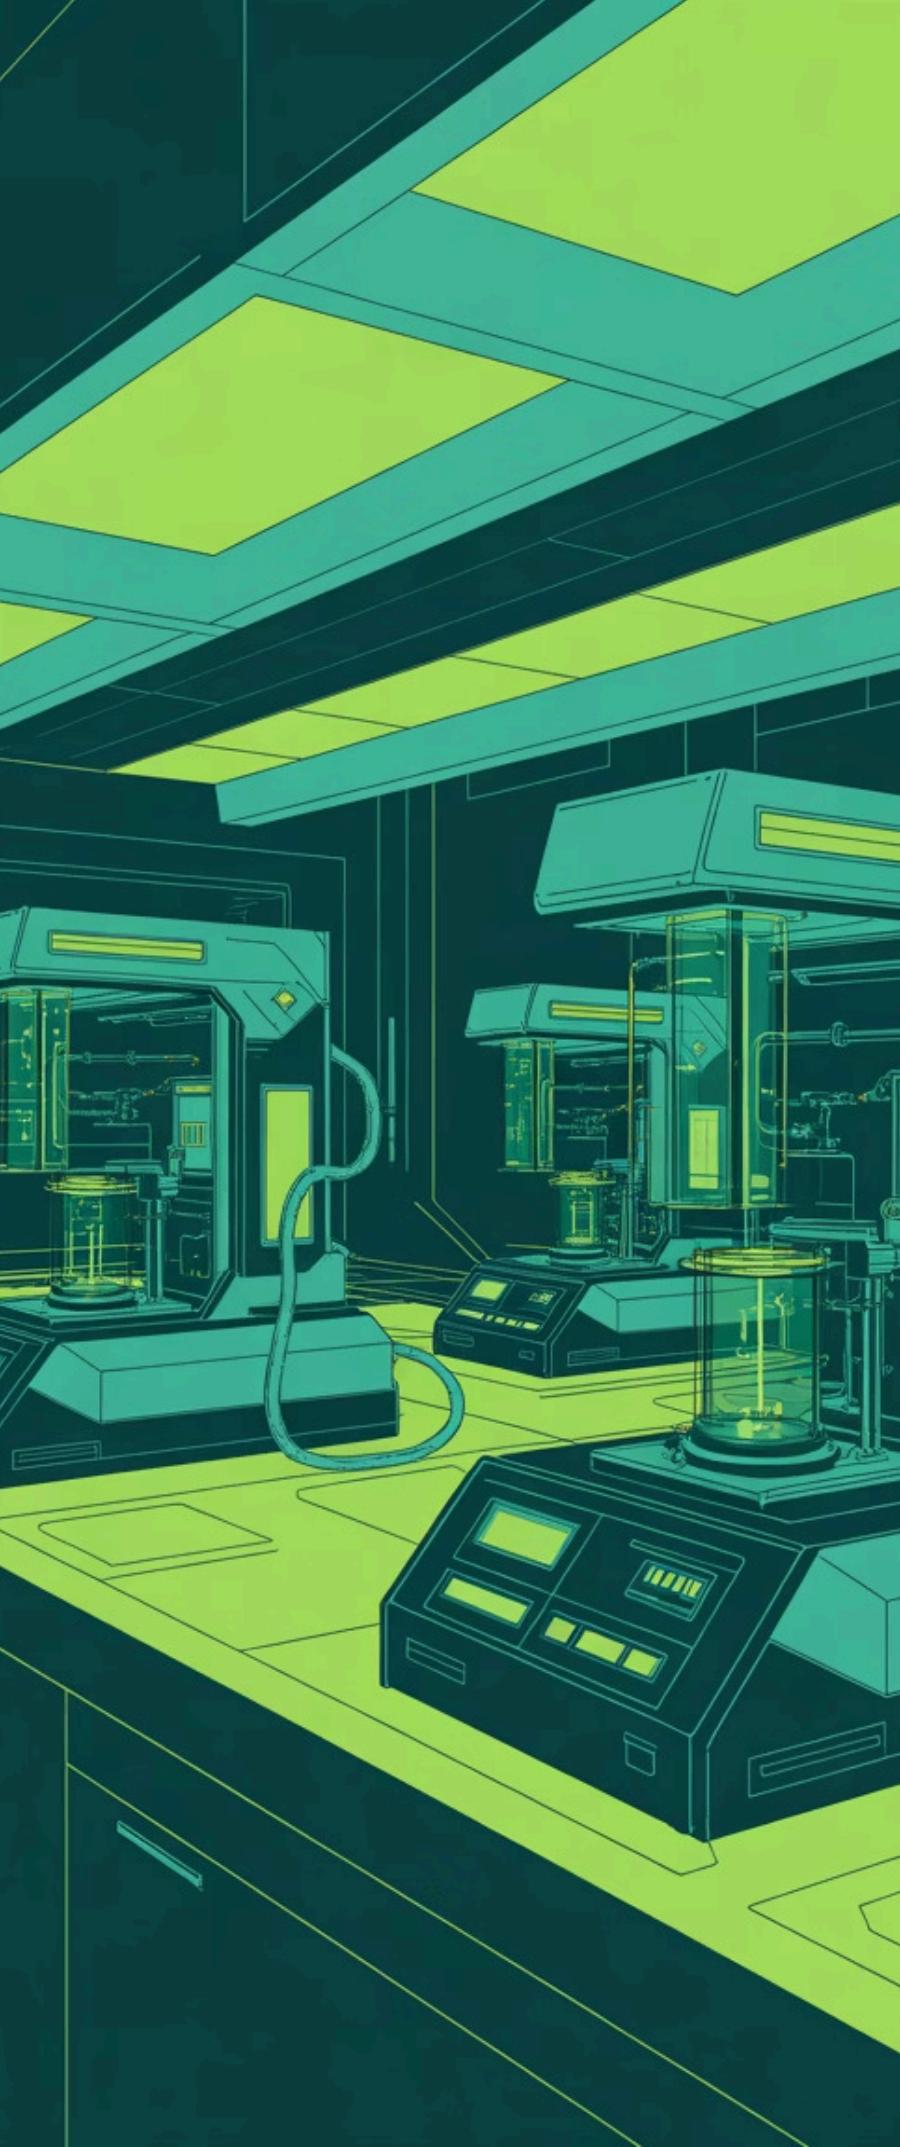
por imagem em GPU

Tamanho

9,81 MB

Modelo final compacto

- ❑ **Viabilidade para Edge:** Modelo leve e rápido o suficiente para dispositivos embarcados



Limitações e Ameaças à Validade



Dataset Homogêneo

Cenário controlado: mesmo fundo, mesma câmera, condições similares



Classes Desbalanceadas

Raspberry e blackberries com menos exemplos, apenas sem sacola



Dependência de Rótulos

Padrões no nome do arquivo podem conter ruído de rotulação

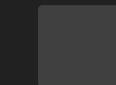


Validação Limitada

Testes apenas em GPU, sem validação cruzada ou hardware real de borda

Resultados promissores, mas generalização para cenários reais requer validação adicional

Conclusões



Acurácia Perfeita

YOLOv8s atingiu **100% de acurácia** nas configurações de 8 e 14 classes



Viável para Produção

Modelo **leve (9,81 MB)** e **rápido (~193 ms)** para balanças inteligentes



Robustez Comprovada

Resistência a variações de iluminação e oclusões dentro do escopo testado



Potencial Transformador

Sistema capaz de revolucionar a experiência de autoatendimento em supermercados



Trabalhos Futuros



Expansão do Dataset

Fotos de diferentes supermercados, câmeras e condições de luz variadas



Cenários Complexos

Frutas danificadas, múltiplos itens, fundos diversos e situações reais de uso



Validação Cross-Dataset

Avaliar generalização em outros datasets públicos e privados



Hardware de Borda Real

Testes em Raspberry Pi, NVIDIA Jetson e outros dispositivos embarcados



Deteção + Classificação

Modelos para cenas com vários itens simultaneamente na balança



Técnicas Avançadas

Data augmentation e balanceamento para reduzir overfitting e melhorar robustez